

# Cahier de charge

## 1. Preview du dataset

	login	name	company	location	total_stars	nb_repos_fetched	languages_list
1 >	sindresorhus	Sindre Sorhus			457146	5	JavaScript, TypeScript
2 >	kamranahmedse	Kamran Ahmed	roadmap.sh	United Kingdom	426260	5	JavaScript, Shell, TypeScript
3 >	torvalds	Linus Torvalds	Linux Foundation	Portland, OR	212950	5	C, OpenSCAD
4 >	getify	Kyle Simpson	Getify Solutions	Austin, TX	203886	5	JavaScript
5 >	openai	OpenAI			174874	5	Jupyter Notebook, Python, Rust, TypeScript

On voit les variables suivantes :

- `login` : **identifiant GitHub**
- `name` : **nom de la personne/organisation**
- `company` : **entreprise ou projet associé**
- `location` : **localisation géographique**
- `total_stars` : **nombre total d'étoiles GitHub sur ses dépôts**
- `nb_repos_fetched` : **nombre de dépôts pris en compte dans le calcul**
- `languages_list` : **principales langues de programmation utilisées (liste séparée par des virgules)**

## 2. Contexte et objectif

- Thème : analyse statistique de développeurs/projets GitHub les plus populaires.

- Objectif général : étudier les caractéristiques des profils GitHub très étoilés et voir comment se répartissent la popularité (`total_stars`) **selon** :
  - les localisations,
  - les entreprises,
  - les langages de programmation.

### 3. Questions de recherche possibles

- Comment se distribue le nombre total d'étoiles (`total_stars`) parmi ces profils ?
- Les profils d'organisations (ex. OpenAI, roadmap.sh) se distinguent-ils des profils individuels ?
- Certaines localisations (pays / régions) concentrent-elles plus de profils très étoilés ?
- Les profils qui utilisent certains langages (ex. JavaScript, Python, C, Rust) ont-ils des niveaux de `total_stars` différents ?
- Y a-t-il une relation entre `nb_repos_fetched` et `total_stars` (plus de dépôts = plus d'étoiles ?) ?

### 4. Données disponibles

- Source : extrait de profils GitHub très populaires (dataset propriétaire/local, pas issu de Kaggle).
- Format : fichier CSV `profiles_index.csv`.
- Observations : ~30 lignes (profils).

- **Variables :**
  - **Qualitatives nominales :** `login`, `name`, `company`, `location`,  
`languages_list`.
  - **Quantitatives :** `total_stars`, `nb_repos_fetched`.

## 5. Méthodologie d'analyse (dans R / Quarto / Colab)

### 1. Import et préparation

- Importer le CSV dans R (`read.csv`).
- Vérifier les types des variables.
- Nettoyer :
  - les valeurs manquantes pour `company` et `location`.
  - transformer `languages_list` en variables analytiques (par exemple, indicateurs binaires par langage : JavaScript, Python, etc.).
  - éventuellement regrouper `location` par pays/régions (Europe, US, etc.).

### 2. Analyse descriptive

- Statistiques descriptives de `total_stars` et `nb_repos_fetched` (moyenne, médiane, min, max, etc.).
- Fréquences pour `company`, `location`, langages principaux.
- Visualisations :
  - histogramme ou boxplot de `total_stars`,
  - barplots pour la présence de certains langages,
  - boxplots de `total_stars` par localisation ou par présence d'un langage (ex. JavaScript vs pas JavaScript).

### 3. Analyse bivariée / inférentielle (simple, vu la taille)

- **Corrélation ou régression simple entre** `total_stars` **et**  
`nb_repos_fetched`.
- **Comparaison de moyennes de** `total_stars` **entre 2 groupes**

### 4. Présentation avec Quarto (ça sera un plus)

Création d' un document `.qmd` :

- introduction (contexte GitHub, objectifs),
- description des données,
- résultats (tableaux + graphiques),
- discussion (interprétation, limites, pistes futures).

## 6. Livrables

- Colab contenant :
  - import des données,
  - nettoyage,
  - analyses descriptives et graphiques,
  - tests/statistiques simples.
- Rapport Quarto(plus):
  - structuré en sections (Introduction, Méthodes, Résultats, Discussion).